CARRERA DE CABALLOS

Predicción de Victorias mediante Modelos de Clasificación y Optimización Bayesiana

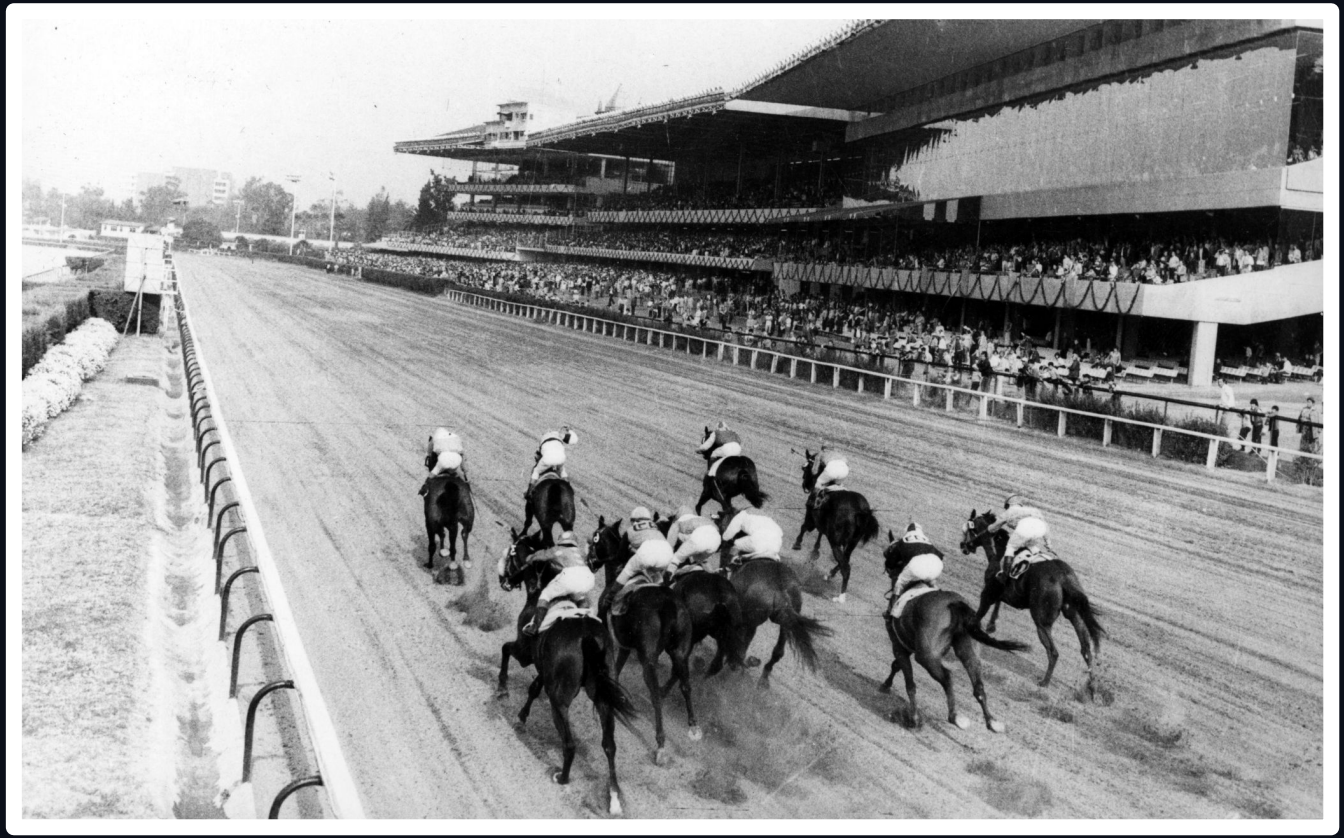

Integrantes

- CARLOS SANTIAGO NAVA PULIDO
- EUGENIO HERNANDEZ ARANDA
- DIEGO DUEÑAS MARTIN

OBJETIVO GENERAL

Analizar el desempeño de tres modelos de clasificación (Regresión Logística, SVM y MLP) para estimar la probabilidad de victoria en carreras de caballos de Hong Kong.

Se utilizan características fundamentales como:

- Raza, jinete y entrenador
- Equipamiento del caballo
- Momios (Pari-Mutuel)

El enfoque metodológico prioriza exclusivamente datos pre-carrera y la estricta gestión del riesgo financiero.

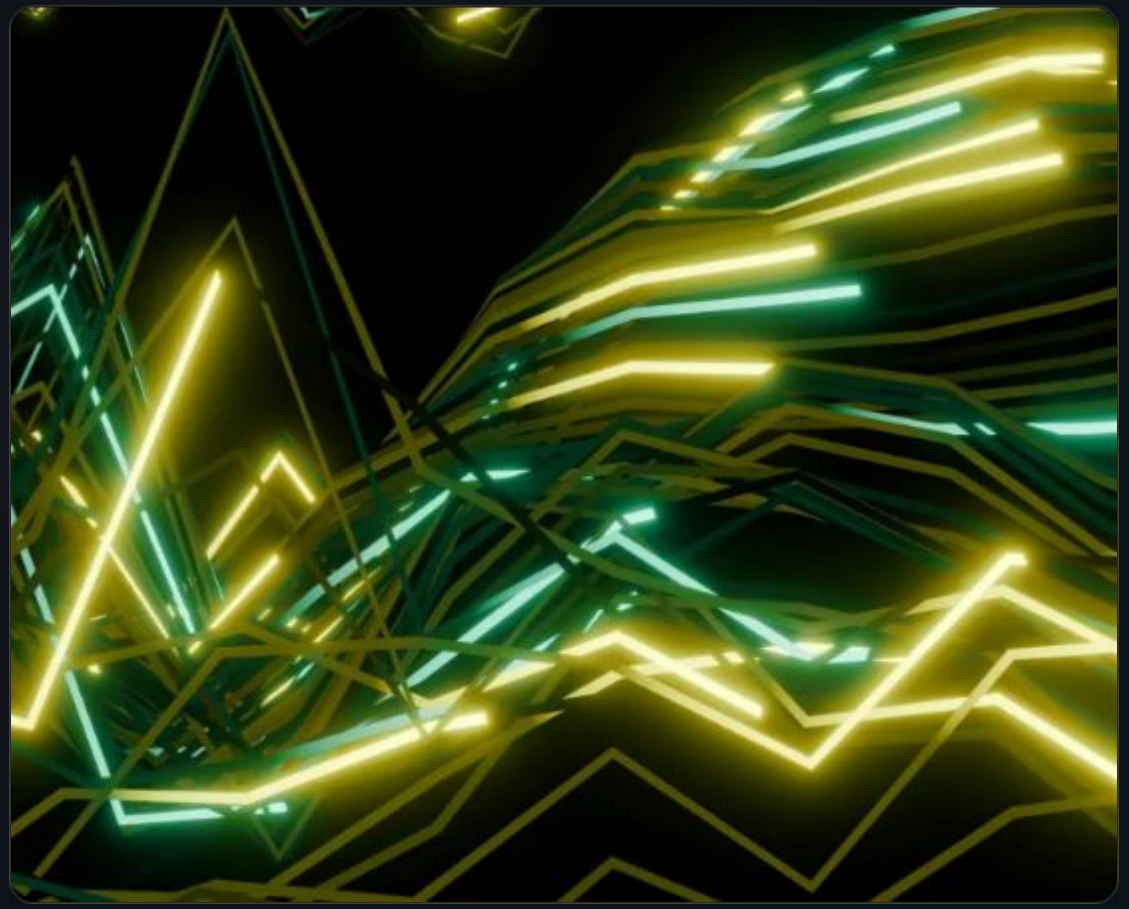

OBJETIVOS ESPECÍFICOS

Ingeniería de Datos

Pipeline con One-Hot Encoding para variables categóricas y transformación logarítmica para los momios debido a su distribución sesgada.

Optimización

Búsqueda Bayesiana con validación cruzada (Cross-Validation) para calibrar eficientemente los tres modelos base.

Gestión de Riesgo

Uso de PR-AUC como métrica principal para penalizar fuertemente los falsos positivos y proteger el capital.

Fronteras de Decisión

Comparar modelos lineales vs. no lineales para capturar la alta complejidad intrínseca de los datos deportivos.

HERRAMIENTAS A UTILIZAR

Regresión Logística

Modelo base que estima probabilidades usando la función sigmoide. Es ideal para entender la influencia lineal y directa de cada variable.

SVM

Support Vector Machine busca el hiperplano que maximiza el margen entre ganadores y perdedores. Es robusto ante múltiples dimensiones.

MLP

Perceptrón Multicapa. Red neuronal que captura relaciones complejas y no lineales, adaptándose a las interacciones sutiles entre variables.

CONCEPTOS TEÓRICOS CLAVE

Kernels

Funciones que permiten al SVM operar en espacios de mayor dimensión sin calcularlos, facilitando la separación no lineal.

Hiperparámetros

Configuraciones externas (tasa de aprendizaje, regularización) que rigen el comportamiento del modelo antes del entrenamiento.

Optimización Bayesiana

Técnica que usa modelos probabilísticos para encontrar eficientemente la mejor configuración en menos iteraciones.

PR-AUC

Métrica que mide el equilibrio entre Precisión y Recall. Superior al ROC-AUC cuando hay fuerte desbalance de clases.

DATASET HK RACING

Origen: Hong Kong Jockey Club (anonimizados en Kaggle).

Tamaño: 79,447 registros, 37 columnas originales.

Estructura: Cada muestra es UN participante en UNA carrera.

Variables clave: horse_id, jockey_id, trainer_id, horse_age, weight, draw, win_odds, won (0 o 1).

Descartadas: Tiempos por tramo (datos post-carrera, ilegales para predicción pre-carrera).

ANÁLISIS EXPLORATORIO (EDA)

SESGO EN LOS MOMIOS (win_odds):
La variable acumula todos los valores mayores a 99 en un límite artificial de 99.0, generando un pico anómalo. Solución: Transformación logarítmica (log1p) antes de entrenar para normalizar.

DESBALANCE DE CLASES:
El 90% de los caballos pierde (won = 0). Esto puede generar métricas infladas pero ficticias. Solución: Uso del parámetro class_weight='balanced' en todos los modelos.

NULOS RELEVANTES:
Solo 2 nulos en horse_country y horse_type. Las columnas con muchos nulos corresponden a tramos opcionales de la pista y fueron eliminadas por ser datos post-carrera.

PREPROCESAMIENTO

1. Limpieza

Filtrado de datos crudos. Eliminación de nulos y columnas con información post-carrera.

2. Sesgadas

Transformación logarítmica: win_odds → log(x+1) + Escalado Estándar.

3. Numéricas

Escalado estándar a horse_age, horse_rating, declared_weight, actual_weight, draw.

4. Categóricas

One-Hot Encoding a IDs, país, tipo. Resulta en un espacio de ~5,000 columnas.

** Los IDs numéricos se convirtieron a texto (strings) previo al encoding.*

Pipeline

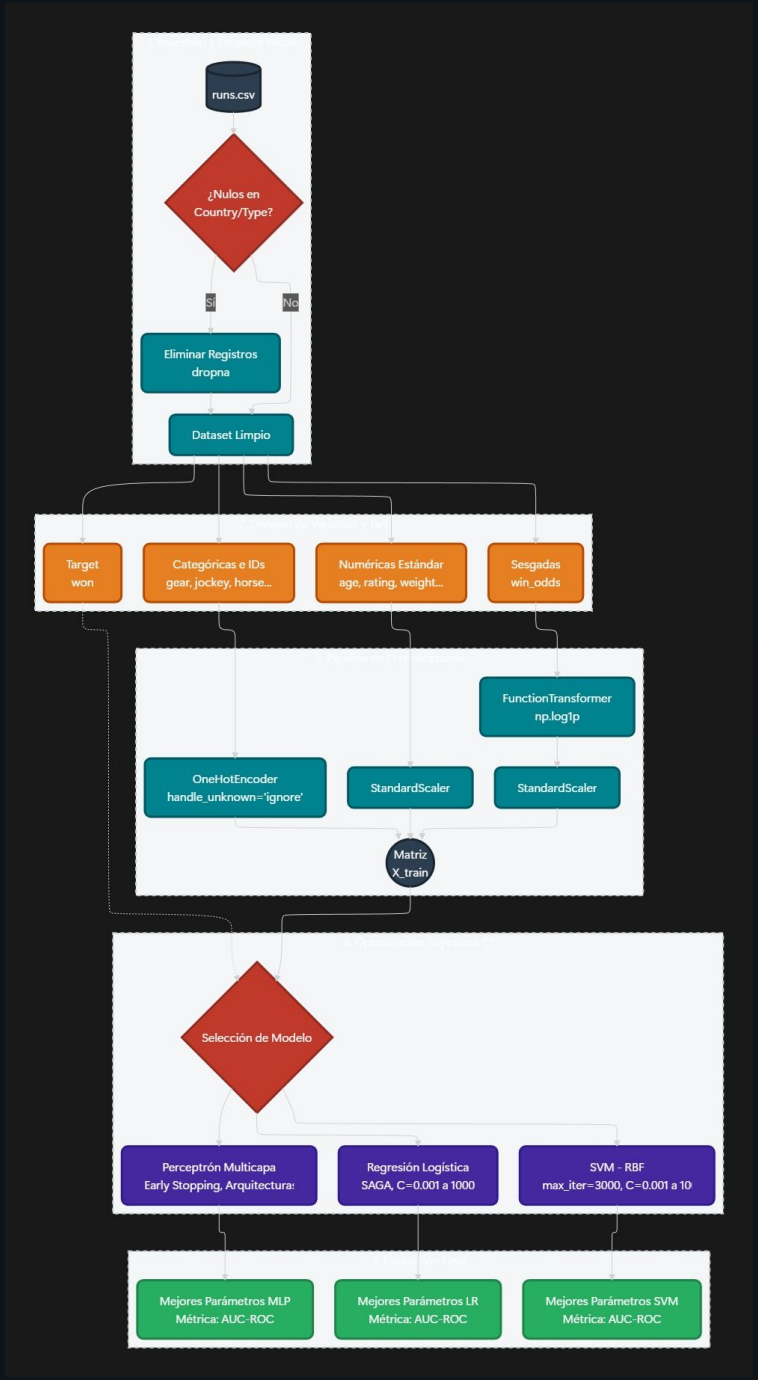
runs.csv
¿Nulos en Country/Type?
Sí
No
Eliminar Registros dropna
Dataset Limpio
Target won
Categóricas e IDs gear, jockey, horse...
Numéricas Estándar age, rating, weight...
Sesgadas win_odds
FunctionTransformer np.log1p
OneHotEncoder handle_unknown='ignore'
StandardScaler
StandardScaler
Matriz X_train
Selección de Modelo
Perceptrón Multicapa Early Stopping, Arquitectura:
Regresión Logística SAGA, C=0.001 a 1000
SVM - RBF max_iter=3000, C=0.001 a 10
Mejores Parámetros MLP Métrica: AUC-ROC
Mejores Parámetros LR Métrica: AUC-ROC
Mejores Parámetros SVM Métrica: AUC-ROC

REGRESIÓN LOGÍSTICA (SAGA)

Configuración

- **Solver:** SAGA (óptimo)
- **Clase balanceada:** Sí
- **Máx. iteraciones:** 2,000
- **Parámetro optimizado:** C (fuerza de regularización)
- **Rango buscado:** 0.001 a 1,000

Resultado

- **Mejor C:** 0.00105
- **Mejor PR-AUC (CV):** 0.2629

Este valor de C muy bajo indica que el modelo prefirió una regularización fuerte, simplificando la solución para evitar ruido.

SVM CON KERNEL RBF

Configuración

- **Kernel:** RBF (No lineal)
- **Clase balanceada:** Sí
- **Máx. iteraciones:** 3,000
- **Parámetros:** C y Gamma
- **C:** Controla el margen
- **Gamma:** Radio de influencia

Resultado

- **Mejor C:** 0.00105 | **Gamma:** 0.0432
- **Mejor PR-AUC (CV):** 0.1644
- **Tiempo entrenamiento:** ~1.5 hrs

Advertencia: El SVM tiene problemas con ~5,000 columnas dispersas provenientes del One-Hot Encoding.

PERCEPTRÓN MULTICAPA (MLP)

⚙ Configuración

- **Early Stopping:** Activado
- **Parámetros optimizados:** hidden_layer_sizes, alpha, lr_init
- **Alpha:** Penaliza pesos grandes
- **LR Init:** Tamaño del paso

🏆 Resultados

- **Prueba 1 (1 capa):** 55 neuronas | alpha: 0.0273 | lr: 0.00623 → PR-AUC: 0.2400
- **Prueba 2 (2 capas):** 150+60 neuronas | alpha: 0.0464 | lr: 0.000215 → PR-AUC: 0.2422

La segunda configuración mejoró ligeramente, demostrando capacidad para patrones no lineales.

MÉTRICA CORRECTA

✕ ACCURACY (Exactitud)

En datos con 90% de caballos que "pierden", un modelo que prediga siempre "pierde" obtendrá un 90% de exactitud. Es una métrica completamente inútil ya que no distingue las victorias reales.

✓ PR-AUC (Precisión-Recall)

Ignora los Verdaderos Negativos. Se enfoca exclusivamente en qué tan bien el modelo detecta victorias reales sin disparar falsas alarmas. Es la métrica correcta para proteger el capital.

¿QUIÉN GANÓ LA CARRERA?

Modelo	PR-AUC	ROC-AUC
🏆MLP (Red Neuronal)	**0.2854**	**0.8002**
Regresión Logística	0.2655	0.7902
SVM	0.1908	0.7102

** Los puntajes finales fueron calculados con el 100% de los datos. El MLP dio un salto notable (de 0.242 a 0.285) al tener acceso a todo el volumen.*

UTILIDAD EN LA PRÁCTICA

Resultados de la Regresión Logística (Simulación Financiera):

Indicador	Cantidad
Apuestas Ganadas (Victorias Reales)	**4,882**
Apuestas Perdidas (Falsas alarmas)	24,954
Capital Protegido (No apostó)	48,131
Oportunidades Perdidas (Ganó sin detectar)	1,478

Contexto: Probabilidad base ~8.33%. Moda de momios 10x. Si el modelo detecta bien, el retorno esperado es positivo.

CONCLUSIONES

🏆MLP Campeón

PR-AUC: 0.2854. Con suficiente volumen de datos, capturó relaciones no lineales que modelos simples ignoraron.

⚖️Logística Consistente

Mismo rendimiento en CV (0.262) y producción (0.265). Sin overfitting. Su fuerte regularización indica señal escasa.

❌SVM Perdedor

Se asfixió con las 5,000 columnas dispersas. Tiempos excesivos (~1.5h) y rendimiento notablemente inferior.

Esperanza Matemática y Gestión de Bankroll

$3100 $16.00 160.0%

ESTRATEGIA RENTABLE

Evolución del Bankroll

$$EV = (P_{ganar} \cdot Ganancia) - (P_{perder} \cdot Pérdida)$$

Con una probabilidad de ganar del 26% y un pago de 5x, tu ganancia esperada por cada $10 apostados es de $3.00.

Precisión (Win Rate) 0.26

Momio (Pago) 10

Tamaño Apuesta ($) 10

Simular 100 Carreras

Reiniciar Bankroll

¿VALIÓ LA PENA?

Se demostró que mediante Machine Learning es posible obtener una ventaja estadística leve pero real sobre las apuestas.

- **Probabilidad base:** ~8.33% (1 de 12).
- **Momios típicos:** 10x de retorno.
- **Impacto:** Se detectan victorias con mayor precisión que el azar, generando esperanza matemática positiva.

Conclusión final: Los modelos logísticos y MLP son viables para clasificar caballos ganadores.

REFERENCIAS

- **Daley, G. (s.f.).** Horse Racing in HK. Kaggle.
- **AWS. (s.f.).** ¿Qué es el ajuste de hiperparámetros?. Amazon Web Services.
- **Britannica. (s.f.).** Pari-mutuel. Encyclopedia Britannica.
- **IBM. (s.f.).** What is a multi-layer perceptron?. IBM Topics.
- **Machine Learning Mastery. (2020).** ROC Curves and Precision-Recall Curves.
- **Scikit-learn. (s.f.).** Logistic Regression / SVM. Documentación oficial.

IMAGE SOURCES

https://developer-blogs.nvidia.com/wp-content/uploads/2025/12/ClickBench-Sirius-1024×576-jpg.webp

Source: developer.nvidia.com

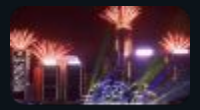

https://www.asiaodysseytravel.com/images/china-tours/group-tours/hong-kong-symphony-of-lights-700-3.jpg

Source: www.asiaodysseytravel.com

---

https://png.pngtree.com/thumb_back/fh260/background/20251222/pngtree-stock-market-line-graph-with-sharp-green-peaks-displayed-over-digital-image_20879461.webp

Source: pngtree.com

---

https://www.eluniversal.com.mx/entrada-de-opinion/colaboracion/mochilazo-en-el-tiempo/nacion/sociedad/2016/09/7/si-algo-me-pasara/

Source: pngtree.com